



AI PROGRAMMING

编程课 机器学习与人工智能

LIFE IS SHORT, YOU NEED AI

主讲人：依力





第三课 大模型

MACHINE LEARNING





1° 基础理解

大模型 (Foundation Model)

指的是在海量数据上预训练，拥有数十亿甚至万亿参数，可以通过微调适应多种下游任务的通用型人工智能模型

比喻	含义
通才学生	大模型通过“通识教育”学会语言、知识、常识等能力，然后可以被训练去做写作、问答、翻译、代码生成等各种任务。
超级大脑	不是专门学某一科目，而是一个“拥有世界知识”的大脑，通过提示（prompt）就能快速应用。
通用工程平台	就像AutoCAD可以画建筑、桥梁、机械图一样，大模型是所有文本任务的通用平台。

“Foundation”意指其为 其他所有下游模型和任务的基础
它不是为了完成一个特定任务训练的，而是“打地基”型模型，可用作：
问答系统的底座、情感分析的底座、多模态生成系统的底座

大模型 (Foundation Model)

关键特征

特征	描述
超大参数规模	参数数亿 ~ 万亿，能表达更复杂的语言与知识结构
🌐 大规模预训练数据	通常使用网页、百科、代码、论文等全网文本训练
统一训练范式	通过统一的“语言建模任务”学到泛化能力
多任务适应性	一个模型可处理问答、翻译、摘要、对话等任务
可微调 (Finetune)	在特定数据或任务上继续训练以提升性能

大模型 (Foundation Model)

发展关键节点

年份	模型	特征
2018	BERT (Google)	革命性地使用Transformer结构和双向语言建模
2020	GPT-3 (OpenAI)	1750亿参数, Few-shot 学习能力首次大放异彩
2022	ChatGPT / GPT-3.5	增加对话微调 (SFT + RLHF), 实用性强大
2023	GPT-4、Claude、LLaMA	多模态输入能力, 长文本理解, 多语言增强
2024-2025	GPT-4o、Gemini 1.5	原生多模态、工具调用、Agent化发展

大模型 (Foundation Model)

大模型与传统小模型对比


特征	传统小模型	大模型
训练数据	一种任务的少量数据	全网大规模文本
参数规模	万 ~ 千万	十亿 ~ 万亿
应用范围	单一任务	多任务、多语言、多模态
适应方式	从头训练	微调、提示工程、检索增强
泛化能力	弱，易过拟合	强，可Zero/Few-shot泛化



2^o 循环神经网络

多层感知机MLP (Multilayer Perceptron)

简单神经网络



输入层




隐藏层



输出层

深度神经网络




循环神经网络

(Recurrent Neural Network, RNN)

专门处理序列数据（如文本、语音、时间序列）的神经网络结构

它的关键特点是：具有“记忆”能力

能够利用前一个时间步的信息来影响当前的输出



RNN的“循环”体现在哪里？

它在每个时间步都会重复使用同一个神经网络单元 (RNN Cell)
并将 上一个时间步的隐藏状态作为输入传递给下一个时间步

读文章，每读一个词 (x_t)
他会把“之前读过的内容”存在脑海里 (h_{t-1})
然后带着这个“记忆”去理解下一个词
这个人的“大脑结构” (即神经网络权重) 没有变
只是“记忆”在不断更新

数据的标签是什么？

语言建模：预测下一个字/词是什么
(类比输入法联想)

模型训练：我想要吃饭

时间步	输入 (X_t)	目标输出 (标签 y_t)
t=1	"我"	"想"
t=2	"想"	"要"
t=3	"要"	"吃"
t=4	"吃"	"饭"

模型训练：我想要吃饭

时间步	输入 (X_t)	目标输出 (标签 y_t)
t=1	"我"	"想"
t=2	"想"	"要"
t=3	"要"	"吃"
t=4	"吃"	"饭"

h_0 = 初始状态 (通常为 0)

$h_1 = f(x_1, h_0) \rightarrow$ 预测 y_1 (= "想")

$h_2 = f(x_2, h_1) \rightarrow$ 预测 y_2 (= "要")

$h_3 = f(x_3, h_2) \rightarrow$ 预测 y_3 (= "吃")

$h_4 = f(x_4, h_3) \rightarrow$ 预测 y_4 (= "饭")

输出层：Softmax激活函数

交叉熵损失函数

共享权重，训练的是同一组权重



You are the only

你是那个唯一

循环神经网络RNN

优点

描述

处理任意长度输入

输入序列长度可变，适合处理文本、语音

捕捉上下文依赖

能记住前面的状态信息，有“上下文感知”能力

应用于 NLP 早期任务

如语言模型、机器翻译、情感分析等

缺点

描述

不能并行训练

序列必须按时间步处理，训练慢

记忆力有限

长距离依赖信息会逐渐丢失（梯度消失）

训练难收敛

对超参数敏感，容易过拟合或震荡




3^o LSTM

长短期记忆网络

Long Short-Term Memory (LSTM)

它引入了专门的结构
记忆单元 (Cell) 和 门控机制 (Gates)



<https://zhengzhong-wang.github.io/2017/07/28/>

门类型	数学符号	作用	类比
忘记门	f_t	决定哪些旧信息要丢弃	清理无用记忆
输入门	i_t	决定哪些新信息要存入	学进来新的知识
输出门	o_t	决定最终要输出什么	说出口的内容



RNN / LSTM 的问题

RNN / LSTM 的问题	描述
序列计算慢	无法并行，只能一个时间步一个时间步处理
长依赖难捕捉	长距离词之间传递信息困难（如：前文主语和后文动词）
难以扩展	对于非常长的文本或多语言处理效果受限


Transformer 被提出，**完全抛弃了 RNN 的时间结构**，转而使用“注意力机制”来建模句子中任何两个词之间的依赖关系



4^o Transformer

Transformer架构

Transformer 是 Google 于 2017 年提出的一种基于注意力机制的神经网络架构，用于处理序列数据。它最早用于机器翻译，现已成为大模型（如 GPT、BERT 等）的核心结构



Self-Attention (自注意力机制)

每个词都可以去“关注”其他词：
比如在“我爱吃小龙虾”中
“吃”这个词可能会特别关注“小龙虾”

Query (我要关注谁)

计算每个词的注意力得分

Key (我值得被关注吗)

$$\text{Attention}(Q, K, V) = \text{softmax}(QK^T / \sqrt{d_k})V$$

Value (我的信息内容)

计算每个词对其他词的相似度 (QK^T)

按照注意力得分加权提取 Value 信息

Multi-Head Attention (多头注意力)

在“自注意力”中，每个词会去关注句子中其他词，看看谁对我当前的理解最重要

一次注意力只能看到一种关系，我想看到多种不同的关系

有一个词“苹果”，可能从不同角度理解：

 主语角度：苹果是被吃的 → 关注“吃”

 语义角度：它是食物 → 关注“饭”

 时序角度：它出现在最后 → 关注“前文”

模型并行从多个角度理解句子中每个词与其他词的关系，让语言理解更立体

位置编码 (Positional Encoding)

Transformer 抛弃了 RNN 的时间结构，所以它本身不知道词序！

解决方法：加上“位置向量”，告诉模型“谁在前谁在后”

如果我们输入 “我 爱 吃 饭” 和 “饭 爱 吃 我”
在模型眼里是完全一样的4个向量

给每个词“贴一个顺序标签” → 位置编码

Transformer 是“全并行处理”的，没有天然顺序，所以必须标注词的顺序



5⁰ 大模型

Transformer 架构 = 大模型的「骨架」

GPT、Grok、Claude、LLaMA...

这些所谓的“大模型”

本质上都是在 Transformer 这个通用架构上堆叠、扩展、微调而成的

能力	原因	作用于大模型
顺序建模能力	Self-Attention 可捕捉任意位置的依赖	理解上下文，生成连贯语句
并行处理能力	所有输入一次性处理，无需逐步	高效训练大规模数据
可扩展性强	结构模块化、可堆叠	堆叠出几十层、上百亿参数
通用性强	不限定任务类型	同一模型能翻译、写诗、写代码

大模型

在 Transformer 基础上做了哪些增强？

增强方向	方法	实际应用
更深更宽	层数更多 (96+) , 宽度更大 (上万维)	GPT-3/GPT-4
更大数据	训练数据从几十G → TB	GPT-3: Common Crawl 等
更好预训练任务	加入指令学习、对话格式、代码混合	ChatGPT, Claude
增强上下文	引入位置编码优化 (RoPE、ALiBi)	LLaMA, Claude
工具接入	增加 Toolformer/函数调用能力	GPT-4o, Claude 3
多模态融合	Vision Transformer + 文本 Transformer	GPT-4o, Gemini, MM-ReAct

Transformer 是大模型的「操作系统内核」

没有 Transformer就没有今天的大语言模型！

如今的大模型

= 巨型堆叠的 Transformer + 多模态接口