



AI PROGRAMMING

编程课 机器学习与人工智能

LIFE IS SHORT, YOU NEED AI

主讲人：依力






第二课

机器学习再入门

MACHINE LEARNING





1° 监督学习

监督学习 (supervised learning)

在给定“输入特征”的前提下，预测相应的“输出标签”

这些“输入-输出对”被称为样本 (example)

数据有真实标签，模型训练是为了学会从特征预测标签

每个样本的输入是特征 (features)，输出是标签 (label)

我们希望模型能“在给定输入特征的前提下，估计标签的概率”

我们通过这些标注数据来训练模型，使其能够泛化到未知输入的预测上

几乎所有工业级 AI 系统（如诊断、翻译、预测）都依赖监督学习

监督学习 (supervised learning)

不同的优化问题有不同的模型

常见学习问题	举例现实实际问题	输入	输出	常见模型
二分类问题	判断邮件是否是垃圾邮件	邮件文本	是 / 否	逻辑回归、决策树、SVM、BERT
多分类问题	图像识别中的手写数字分类	图片像素 (如 28×28)	数字 0 ~ 9	CNN、KNN、Softmax回归、ResNet
线性回归	房价预测	面积、房间数、地段等特征	连续数值 (如房价)	线性回归、Lasso、SVR
非线性回归	股票价格预测	历史股价、交易量、经济指标	连续数值 (如明日开盘价)	随机森林、XGBoost、LSTM
多标签分类	给图片打多个标签 (如风景+夜景)	图像特征向量	多个标签的集合	神经网络 (sigmoid输出层)、BERT
序列预测	预测明天的天气	历史温度、湿度、风速序列	未来几天的温度	RNN、LSTM、GRU、Transformer
机器翻译	英文翻译成中文	一段英文句子	中文句子	Seq2Seq、Transformer、T5
图像优化	将草图生成彩色图像	黑白草图	彩色图像	GAN、Diffusion、VAE
强化学习问题	自动驾驶决策	当前状态 (车速、距离)	动作选择 (加速、转向等)	Q-learning、DQN、PPO
异常检测	信用卡欺诈识别	交易金额、时间、地点等特征	正常 / 异常	Isolation Forest、AutoEncoder
推荐系统	给用户推荐电影	用户历史评分、观看记录等	推荐电影清单	协同过滤、矩阵分解、深度推荐模型

监督学习 (supervised learning)

模型构建过程存在的问题和挑战

标注成本高

标签需人工或专家标注，成本大

过拟合风险

在训练集表现好，测试集表现差

样本不均衡问题

一些标签（如罕见病）样本很少，
导致模型偏向常见类别

泛化能力差

在真实环境中遇到新分布（分布漂
移），模型可能失败



2° 无监督学习

无监督学习 (unsupervised learning)

数据没有人为标注的标签

模型需要自己从数据中发现结构、模式或规律

老师给你发了本次考试的结果和你的答题卡，
问你“你觉得自己有什么问题？”

男/女朋友向你提出灵魂之问：你觉得自己错在哪了？

你加入了课题组，学长给了你10篇论文说：你自己研究吧

没有标准答案，模型要自己从数据中“学会看门道”

无监督学习 (unsupervised learning)

常见学习问题	举例现实实际问题	输入	输出	常见模型 / 方法
聚类 (Clustering)	根据用户浏览行为划分用户类型	用户网页点击、停留时间、浏览路径	用户被分配到某一类群体	K-Means、DBSCAN、层次聚类 (Hierarchical)
主成分分析 (PCA)	选校择业的个性评估	图像的像素数据、文本TF-IDF矩阵	几个主成分构成的低维向量	PCA、t-SNE、LLE、UMAP
异常检测 (Anomaly Detection)	发现金融欺诈、工业设备故障	传感器时间序列、交易记录	是否属于“异常”样本 (无需标签监督)	高斯混合模型 (GMM)、Isolation Forest、AutoEncoder
概率图模型 (PGM)	描述房价、学区、污染、地理位置之间关系	多种社会经济变量	变量之间的因果关系结构	贝叶斯网络、马尔科夫网络
生成模型 (Generation)	生成写实的 AI 头像、图像风格迁移	图像、语音、文本 (真实数据)	模拟生成的图像、音频或文本数据	GAN、VAE、Diffusion Model
词嵌入学习 (Embedding)	学习词与词之间的语义关系	单词及其上下文句子	每个词的向量表示	Word2Vec、GloVe、FastText
自编码器 (AutoEncoder)	无监督学习图像/文本特征	原始数据 (图像、文本)	压缩后的特征 + 重建数据	AutoEncoder、变分自编码器 (VAE)

无监督学习有损失函数和优化算法吗？

虽然没有明确的“标签”作为监督信号
但无监督学习中依然要衡量模型的“好坏”
这就需要定义某种“目标”来进行优化，表现为一个 损失函数

虽然没有“真实答案”
我们仍然可以构造一个目标函数来“间接定义什么是好”

无论有监督还是无监督 本质上都是“离线学习”

模型不会主动去影响环境或采集新数据


所有数据（训练集、测试集）已经提前收集好

模型只是从固定数据中“学习模式”

模型不会主动去影响环境或采集新数据

所有数据（训练集、测试集）已经提前收集好

模型只是从固定数据中“学习模式”



在线学习 (Online Learning)

模型逐步接收新数据更新 (API接口、爬虫等)
但仍不主动影响环境

股票价格预测、广告点击率预估

但预测远远不够

人工智能的目标不仅是识别信息、预测未来
而是能与环境“对话”和“作用”

我们希望模型不只是预测器 (Predictive Model)
而是智能体 (Agent)，**我们需要模型和环境交互**

当前环境的状态是否依赖于我们的历史行为？ 环境还记得我们以前做过什么吗？

如果环境“有记忆”，你之前的动作会影响它现在的状态

玩迷宫游戏：你走过的路线会影响你现在的位置

对话系统：你前几句话的内容会影响对方接下来怎么回答

部分可观测马尔可夫决策过程 (POMDP
Partially Observable Markov Decision Process)

因为模型无法看到全部信息，只能通过历史行为和观测来“猜测”当前环境

环境是否有助于我们建模？ 环境能不能提供一些反馈，帮助我们更好地学习？

环境能否提供奖励或反馈机制

自动驾驶：如果系统判断你刹车刹得及时，给你一个正反馈

游戏AI：每次打败敌人得分越高，模型学得越快

GPT：受到用户正向称赞和夸奖，或者点击选择更优答案，模型知道如何更好的取悦人类

强化学习中的“奖励信号设计”

设计好奖励机制，模型就能学会正确的行为

我们和环境是不是对立的？
环境有自己的目标，甚至是“敌人”

下围棋：你的对手是环境的一部分，他会想尽办法赢你

安全对抗AI：比如你是防火墙系统，而攻击者在不断变化手段

博弈论 (Game Theory)

min-max 博弈、对抗性训练 (GAN)

环境是否会变？

环境总是一样的，还是会随时间或空间变化？

疫情预测模型：病毒传播机制和数据不断在变。

用户推荐系统：用户兴趣随季节、热点变化
今天喜欢、明天可能不喜欢。

分布漂移 (concept drift)

环境不再服从原始训练数据的分布，模型必须应对变化

环境是否重要？

我能不能忽略环境建模？这样是不是更简单？

猫狗识别：你只需要看图片，不需要管环境（背景）

自动驾驶：你不能忽略环境，道路、行人、红绿灯全都是核心信息

如果目标是自主智能体 (Autonomous Agent)
环境建模是不可或缺的

忽略环境可以简化问题（比如只做图像分类）




3^o 强化学习

强化学习 (Reinforcement Learning)

RL是一类智能体 (agent) 通过与环境 (environment) 交互学习
最优行为策略 (policy) 的学习方法
其核心思想是“试错”
智能体在环境中采取动作 (action)
获得奖励 (reward) 或惩罚, 以此指导未来的决策

与监督学习不同, 强化学习并不直接提供“正确的标签”
而是提供稀疏或延迟的反馈信号 (其实也是一种标签, 但可能不及时)

强化学习 (Reinforcement Learning)



1. 状态观测 (Observation / State)

智能体观察当前环境的状态 s_t

2. 动作选择 (Action)

智能体根据当前策略 π , 在状态 s_t 下选择一个动作 a_t

3. 环境反馈 (Transition)

动作 a_t 被执行, 环境转移到新状态 s_{t+1} , 并产生一个即时奖励 r_t

4. 策略更新 (Learning)

智能体利用 (s_t, a_t, r_t, s_{t+1}) 经验进行策略或价值函数的更新

5. 重复步骤 1~4, 直到终止

$$G_t = \sum_{k=0}^{\infty} \gamma^k r_{t+k}$$

$\gamma \in [0, 1]$: 折扣因子, 衡量未来奖励的价值 (越小越“短视”)

**但我们依然还是尝试用
数据、模型、目标函数、优化算法 四个方面去理解**

强化学习的数据

从“静态样本”到“环境交互”

监督学习中是一堆 (x, y) 特征、标签，全部数据静态可见

强化学习中的“数据”来自智能体与环境不断交互，具体包括：

- 当前状态 s_t
- 智能体采取的动作 a_t
- 环境返回的奖励 r_t
- 环境转移到的新状态 s_{t+1}

$$(s_t, a_t, r_t, s_{t+1})$$

强化学习的模型（策略）

强化学习的模型目标是学出一个策略

$\pi(a|s)$ = 在状态 s 下选择动作 a 的概率

有时还引入：

- 状态-动作值函数（Q-function）：

$$Q^\pi(s, a) = \mathbb{E}[\text{未来的累计奖励} | s_t = s, a_t = a, \pi]$$

- 状态值函数：

$$V^\pi(s) = \mathbb{E}_{a \sim \pi(\cdot|s)}[Q^\pi(s, a)]$$

强化学习的目标函数

强化学习不再是“拟合标签”，而是追求长期奖励最大化

$$\max_{\pi} \mathbb{E}_{\pi} \left[\sum_{t=0}^{\infty} \gamma^t r_t \right]$$

马尔可夫性 (Markov Property)

当前状态所包含的信息足以决定未来状态的转移概率
与历史路径无关

$$P(s_{t+1} | s_t, a_t, s_{t-1}, a_{t-1}, \dots, s_0, a_0) = P(s_{t+1} | s_t, a_t)$$

过去对未来的影响全部通过现在传递，即“无记忆性”假设


MDP (Markov Decision Process, 马尔可夫决策过程)



第三课

模型与算法

MACHINE LEARNING



哈喽，8周年周年庆开启啦！[爆竹][爆竹][爆竹]吐血底价+送课+抽红包+礼品等优惠多多

1《Python数据分析与挖掘就业班》签订保薪水协议，一线城市就业薪资预期不低于20k，二线就业不低于15k

2AI大模型智能体（工作赋能和兼职副业）

3Tiktok跨境电商陪跑营（兼职副业和就业）

4小红书电商副业陪跑营（兼职副业）

5网络安全就业

6爬虫逆向副业班

7嵌入式开发就业课



[爱心]了解哪个课程回复相应数字
职业规划回复【666】



1° 线性神经网络

线性回归 (Linear Regression)

$$y_i = w_i^\top x + b_i$$



线性回归 (Linear Regression)

决定系数 (R^2 , R-squared), 也叫 拟合优度, 用于衡量回归模型对数据的解释能力

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

其中:

- y_i : 真实值
- $\hat{y}_i$: 模型预测值
- $\bar{y}$: 真实值的平均值
- 分子: 模型的 残差平方和 (RSS), 表示预测误差
- 分母: 总平方和 (TSS), 表示数据本身的变动性

如果 $R^2 = 0.8$
模型解释了 80% 的目标变量变化

Graduate Admissions

数据集链接 (Kaggle) :

<https://www.kaggle.com/datasets/mohansacharya/graduate-admissions>

预测学生被美国研究生院（主要是工科/理科）录取的概率

列名	含义	类型
Serial No.	序号（无实际意义，仅作编号）	整数
GRE Score	GRE 总分（满分340）	数值型
TOEFL Score	TOEFL 分数（满分120）	数值型
University Rating	申请学校评级（1 – 5，越高越好）	整数型
SOP	Statement of Purpose 陈述评分（1 – 5）	浮点型
LOR	推荐信质量评分（1 – 5）	浮点型
CGPA	本科 GPA（满分10）	浮点型
Research	是否有科研经历（0 = 无，1 = 有）	二元分类
Chance of Admit	录取概率（0 – 1 之间）目标变量	浮点型